

# C19 Algorithmes des textes

## 1. Position du problème

### Définitions et notations

On s'intéresse au problème de la recherche d'une chaîne de caractères appelée **motif** dans une autre chaîne de caractères appelée **texte**. Plus précisément, on veut lister toutes les occurrences (par leur position) du motif dans le texte.

On notera :

# C19 Algorithmes des textes

## 1. Position du problème

### Définitions et notations

On s'intéresse au problème de la recherche d'une chaîne de caractères appelée **motif** dans une autre chaîne de caractères appelée **texte**. Plus précisément, on veut lister toutes les occurrences (par leur position) du motif dans le texte.

On notera :

- $m$  le motif et  $l_m$  sa longueur

# C19 Algorithmes des textes

## 1. Position du problème

### Définitions et notations

On s'intéresse au problème de la recherche d'une chaîne de caractères appelée **motif** dans une autre chaîne de caractères appelée **texte**. Plus précisément, on veut lister toutes les occurrences (par leur position) du motif dans le texte.

On notera :

- $m$  le motif et  $l_m$  sa longueur
- $t$  le texte et  $l_t$  sa longueur

# C19 Algorithmes des textes

## 1. Position du problème

### Définitions et notations

On s'intéresse au problème de la recherche d'une chaîne de caractères appelée **motif** dans une autre chaîne de caractères appelée **texte**. Plus précisément, on veut lister toutes les occurrences (par leur position) du motif dans le texte.

On notera :

- $m$  le motif et  $l_m$  sa longueur
- $t$  le texte et  $l_t$  sa longueur

D'autre part, parfois le problème se réduira à déterminer si  $m$  est présent ou non dans  $t$ , ou encore on cherchera uniquement la première occurrence.

# C19 Algorithmes des textes

## 1. Position du problème

### Définitions et notations

On s'intéresse au problème de la recherche d'une chaîne de caractères appelée **motif** dans une autre chaîne de caractères appelée **texte**. Plus précisément, on veut lister toutes les occurrences (par leur position) du motif dans le texte.

On notera :

- $m$  le motif et  $l_m$  sa longueur
- $t$  le texte et  $l_t$  sa longueur

D'autre part, parfois le problème se réduira à déterminer si  $m$  est présent ou non dans  $t$ , ou encore on cherchera uniquement la première occurrence.

### Exemple

La recherche du motif  $m=\text{exe}$  ( $l_m = 3$ ) dans le texte  $t=\text{un excellent exemple et un exercice extraordinaire}$  ( $l_t = 50$ ) doit produire la liste d'occurrences :  $[13; 27]$ .

# C19 Algorithmes des textes

## 1. Position du problème

### Définitions et notations

On s'intéresse au problème de la recherche d'une chaîne de caractères appelée **motif** dans une autre chaîne de caractères appelée **texte**. Plus précisément, on veut lister toutes les occurrences (par leur position) du motif dans le texte.

On notera :

- $m$  le motif et  $l_m$  sa longueur
- $t$  le texte et  $l_t$  sa longueur

D'autre part, parfois le problème se réduira à déterminer si  $m$  est présent ou non dans  $t$ , ou encore on cherchera uniquement la première occurrence.

### Exemple

La recherche du motif  $m=\text{exe}$  ( $l_m = 3$ ) dans le texte  $t=\text{un excellent exemple et un exercice extraordinaire}$  ( $l_t = 50$ ) doit produire la liste d'occurrences : [13 ; 27].

un\_excellent\_exemple\_et\_un\_exercice\_extraordinaire  
0                  13                  27                  49

### Recherche naïve

Pour recherche si un motif  $m$  se trouve dans une chaîne  $c$ , on peut :

- 1 parcourir chaque caractère de la chaîne  $c$

### Exemple

Visualisation en ligne du fonctionnement de l'algorithme

### Recherche naïve

Pour recherche si un motif  $m$  se trouve dans une chaîne  $c$ , on peut :

- 1 parcourir chaque caractère de la chaîne  $c$
- 2 si ce caractère correspond au premier caractère du motif  $m$ , alors on avance dans le motif tant que les caractères coïncident.

### Exemple

Visualisation en ligne du fonctionnement de l'algorithme



### Recherche naïve

Pour recherche si un motif **m** se trouve dans une chaîne **c**, on peut :

- 1 parcourir chaque caractère de la chaîne **c**
- 2 si ce caractère correspond au premier caractère du motif **m**, alors on avance dans le motif tant que les caractères coïncident.
- 3 si on atteint la fin du motif, alors **m** se trouve dans **c**. Sinon on passe au caractère suivant de **c**.

### Exemple

Visualisation en ligne du fonctionnement de l'algorithme

### Proposition d'implémentation en Python

```
def recherche(motif, chaine):  
    lm, lc = len(motif), len(chaine)  
    for i in range(lc - lm + 1):  
        i_motif, i_chaine = 0, i  
        while i_motif < lm and chaine[i_chaine] == motif[i_motif]:  
            i_motif += 1  
            i_chaine += 1  
        if i_motif == lm:  
            return True  
    return False
```

# C19 Algorithmes des textes

## 2. Recherche naïve

### Coût de la recherche simple

Soient  $l_m$  la longueur du motif et  $l_c$  celle de la chaîne, on vérifie que l'algorithme de recherche simple demande au plus  $l_m(l_c - l_m + 1)$  comparaisons

### Exemple

Combien de comparaisons seront nécessaires si on recherche le motif **bbbbbbbbbba** (neuf fois le caractère **b** suivi d'un **a**) dans une chaîne contenant un million de **b** ?

### Accélération de la recherche

Supposons qu'on recherche le motif `extra` dans la chaîne `un excellent exemple et un exercice extraordinaire`. La comparaison naïve ci-dessus commence par :

### Accélération de la recherche

Supposons qu'on recherche le motif **extra** dans la chaîne **un excellent exemple et un exercice extraordinaire**. La comparaison naïve ci-dessus commence par :

u	n		e	x	c	e	l	l	e	n	t
$\updownarrow$											
e	x	t	r	a							

### Accélération de la recherche

Supposons qu'on recherche le motif **extra** dans la chaîne **un excellent exemple et un exercice extraordinaire**. La comparaison naïve ci-dessus commence par :

u	n		e	x	c	e	l	l	e	n	t
---	---	--	---	---	---	---	---	---	---	---	---



e	x	t	r	a							
---	---	---	---	---	--	--	--	--	--	--	--

Deux idées vont permettre d'accélérer la recherche :

### Accélération de la recherche

Supposons qu'on recherche le motif **extra** dans la chaîne **un excellent exemple et un exercice extraordinaire**. La comparaison naïve ci-dessus commence par :

u	n		e	x	c	e	l	l	e	n	t
---	---	--	---	---	---	---	---	---	---	---	---



e	x	t	r	a							
---	---	---	---	---	--	--	--	--	--	--	--

Deux idées vont permettre d'accélérer la recherche :

- Commencer par la fin du motif.

### Accélération de la recherche

Supposons qu'on recherche le motif **extra** dans la chaîne **un excellent exemple et un exercice extraordinaire**. La comparaison naïve ci-dessus commence par :

u	n		e	x	c	e	l	l	e	n	t
---	---	--	---	---	---	---	---	---	---	---	---



e	x	t	r	a							
---	---	---	---	---	--	--	--	--	--	--	--

Deux idées vont permettre d'accélérer la recherche :

- Commencer par la fin du motif.
- Prétraiter le motif de façon à éviter des comparaisons inutiles.



### Accélération de la recherche

Dans l'exemple ci-dessus cela donne :


### Accélération de la recherche

Dans l'exemple ci-dessus cela donne :

u	n		e	x	c	e	l	l	e	n	t
				↑	↓						
e	x	t	r	a							

### Accélération de la recherche

Dans l'exemple ci-dessus cela donne :



On peut avancer directement de 3 emplacements car le dernier **x** se trouve à 3 emplacements de la fin du motif.

### Accélération de la recherche

Dans l'exemple ci-dessus cela donne :

u	n		e	x	c	e	l	l	e	n	t
				↕							

e	x	t	r	a							
---	---	---	---	---	--	--	--	--	--	--	--

On peut avancer directement de 3 emplacements car le dernier **x** se trouve à 3 emplacements de la fin du motif.

u	n		e	x	c	e	l	l	e	n	t
---	---	--	---	---	---	---	---	---	---	---	---

			↕								
			e	x	t	r	a				

# C19 Algorithmes des textes

## 2. Recherche naïve

### Accélération de la recherche

Dans l'exemple ci-dessus cela donne :

u	n		e	x	c	e	l	l	e	n	t
				↕							

e	x	t	r	a							
---	---	---	---	---	--	--	--	--	--	--	--

On peut avancer directement de 3 emplacements car le dernier **x** se trouve à 3 emplacements de la fin du motif.

u	n		e	x	c	e	l	l	e	n	t
				↕							

			e	x	t	r	a				
--	--	--	---	---	---	---	---	--	--	--	--

Cette fois, le **l** ne se trouve pas dans le motif, on peut donc avancer de la longueur du motif.

# C19 Algorithmes des textes

## 2. Recherche naïve

### Accélération de la recherche

Dans l'exemple ci-dessus cela donne :

u	n		e	x	c	e	l	l	e	n	t
				↕							

e	x	t	r	a							
---	---	---	---	---	--	--	--	--	--	--	--

On peut avancer directement de 3 emplacements car le dernier **x** se trouve à 3 emplacements de la fin du motif.

u	n		e	x	c	e	l	l	e	n	t
				↕							

			e	x	t	r	a				
--	--	--	---	---	---	---	---	--	--	--	--

Cette fois, le **l** ne se trouve pas dans le motif, on peut donc avancer de la longueur du motif.

Visualisation en ligne du fonctionnement de l'algorithme accéléré

### Remarques

- L'implémentation, plus délicate que la recherche naïve fait l'objet d'un exercice.

### Remarques

- L'implémentation, plus délicate que la recherche naïve fait l'objet d'un exercice.
- L'étude du coût de cet algorithme n'est pas au programme, mais à titre d'exemple, on pourra rechercher le nombre de comparaisons de la recherche du motif `aaaaaaaaaa` dans un texte contenant un million de `b` et comparer avec le cas de la recherche naïve.